

# **GenZ Working Environment**

## **Modelo de clasificación binaria + API REST**

### **(Flask + ngrok)**

### **UDD Bootcamp – Módulo 7**

Autor: Elías Aburto

# Problema

¿Qué queremos predecir?

- Preferencia de ambiente laboral de Gen Z
- Dos resultados:
  - **REMOTE** (incluye híbrido y full remote)
  - **FULL\_OFFICE** (oficina todos los días)

¿Para qué sirve?

- Apoyar decisiones de políticas de trabajo y atracción de talento




# Dataset

Fuente: Understanding career aspirations of GenZ (KultureHire / Kaggle)

Tamaño: 235 respuestas

Dato clave: ~98% de respuestas provienen de India (limitación de generalización)




# Definición del target

**Target original:** 6 categorías de “working environment”

**Nuestra definición binaria:**

- FULL\_OFFICE = “Every Day Office Environment”
- REMOTE = resto (Hybrid + Fully Remote)



# Variables usadas

**12 variables de entrada (11 categóricas + 1 numérica)**

Ejemplos:

- País, género
- Preferencias de aprendizaje, tipo de manager, setup del equipo
- Escala 0–10 sobre “misión sin impacto social”

# Metodología


## Pipeline end-to-end

1. Limpieza y EDA
2. Preprocesamiento:
  - categorías raras → OTHER
  - OneHotEncoder
3. Entrenamiento:
  - Logistic Regression (tuned)
4. Evaluación (test)




# Distribución por género y preferencia

- Comparación del porcentaje de REMOTE vs FULL\_OFFICE por género.
- En este dataset, **ambos géneros muestran alta preferencia por REMOTE**, con diferencias moderadas.
- Sirve para entender si la preferencia por remoto cambia según el perfil.




# Curva ROC

- **ROC**: muestra el intercambio entre “falsos positivos” y “verdaderos positivos” al variar el umbral.
- **AUC (ROC)** resume el rendimiento general (más alto = mejor separación).



# Precision-Recall

- **ROC**: muestra el intercambio entre “falsos positivos” y “verdaderos positivos” al variar el umbral.
- **AUC (ROC)** resume el rendimiento general (más alto = mejor separación).
- **Precision–Recall** es especialmente útil cuando hay **clase minoritaria** (aquí: FULL\_OFFICE).
- **AP (Average Precision)** resume la curva PR (más alto = mejor balance precisión/recall).




# Resultados del modelo (métricas)

Accuracy (test): 0.7021

F1 Macro: 0.6278

Por clase (idea simple):

- REMOTE se predice mejor (clase mayoritaria)
- FULL\_OFFICE es más difícil (clase minoritaria)



# Tuning y ensambles

Qué se hizo para mejorar el modelo:

- Tuning de hiperparámetros en Logistic Regression
- Comparación con modelos base (ej.: RandomForest / GradientBoosting)
- Selección final por balance entre métricas (F1 macro + estabilidad)

**Mensaje:** intentamos reducir varianza y mejorar rendimiento antes de producción

# API REST pública

**Tecnología:** Flask + ngrok

**Endpoint:** POST /predict

**Respuesta:** predicción + confidence

# Conclusiones

- **El proyecto cumple un flujo end-to-end reproducible:** EDA → modelo → tuning/ensamble → API pública con confianza.
- **La principal limitación es la generalización:** la muestra está concentrada en India y FULL\_OFFICE es minoritaria; mejorar esto requerirá más datos y/o estrategias de balanceo.
- Buen rendimiento en REMOTE, menor en FULL\_OFFICE por desbalance.